Comparación de Redes Metabólicas: Estado Sano vs. Estado Enfermo

Javier Roberto Rubalcava Cortés
Posgrado en Ciencias Matemáticas, UNAM
Ciudad de México, México

***Resumen*—Se compararon dos redes de rutas metabólicas reconstruidas a partir de datos metagenómicos, una correspondiente a individuos sanos y otra a individuos enfermos. Ambas redes comparten 619 nodos y fueron analizadas con NetworkX mediante métricas topológicas globales, análisis diferencial de aristas, pruebas estadísticas no paramétricas y modelos nulos basados en permutación y modelo de configuración. La red enferma presentó más aristas que la red sana (1,215 vs. 876), así como mayor densidad y mayor grado promedio. Aunque las distribuciones de grado no mostraron diferencias significativas en las pruebas no paramétricas clásicas, la prueba de permutación indicó una diferencia significativa en el grado promedio ($\Delta\bar{k} = 1.0953$, $p = 0.0067$), resultado confirmado por el modelo de configuración ($p < 0.0001$), que controla por la diferencia en el número de aristas entre redes. El análisis funcional mostró que la ganancia de conectividad se concentra en rutas de metabolismo de carbohidratos, mientras que el metabolismo central y energético es la única categoría con pérdida neta. En conjunto, los resultados sugieren una reorganización topológica específica de las rutas metabólicas asociada al estado de enfermedad.**

***Palabras clave*—metagenómica, redes metabólicas, análisis diferencial de redes, microbioma, prueba de permutación**

I. Introducción

La metagenómica ha transformado nuestra capacidad de caracterizar las comunidades microbianas presentes en muestras ambientales y clínicas, ofreciendo acceso sin precedentes a la diversidad funcional del microbioma. En particular, la reconstrucción de redes de rutas metabólicas a partir de datos metagenómicos permite representar las capacidades bioquímicas colectivas de una comunidad microbiana como un grafo, donde los nodos son rutas metabólicas y las aristas reflejan co-ocurrencia o interacción funcional entre ellas [1].

El análisis diferencial de redes biológicas (comparar la topología de una red en dos condiciones) ha emergido como un enfoque poderoso para identificar reorganizaciones estructurales asociadas a estados patológicos. A diferencia del análisis de expresión diferencial gen a gen, el enfoque de redes captura dependencias relacionales entre componentes y permite detectar módulos o *hubs* cuya conectividad cambia entre condiciones [2].

En este trabajo se aplica dicho enfoque a dos redes metabólicas derivadas de datos metagenómicos: una correspondiente a individuos sanos y otra a individuos con una condición de enfermedad, con el objetivo de caracterizar las diferencias topológicas entre ambos estados.

II. Materiales y métodos

II-A. Datos de entrada

Se utilizaron dos matrices de adyacencia en formato CSV:

- Red sana: H_adjcent_path_completeNET.csv
- Red enferma: DD_adjcent_path_completeNET.csv

Cada matriz tiene dimensiones 619×619, donde las filas y columnas representan rutas metabólicas identificadas por sus códigos en la base de datos MetaCyc/HUMAnN (i.e., PWY-7277, TRIGLSYN-PWY). Los valores de entrada fueron binarizados: cualquier valor mayor que cero se codificó como 1 (arista presente) y cero como ausente.

II-B. Construcción de los grafos

Ambas matrices se alinearon al mismo conjunto de nodos mediante reindexación, completando con ceros las entradas faltantes. Se construyeron grafos no dirigidos con la biblioteca NetworkX [3]. El conjunto final compartido consta de 619 nodos.

II-C. Métricas topológicas globales

Para cada red se calcularon las siguientes métricas:

- Número de nodos y aristas.
- Densidad de la red: proporción de aristas presentes respecto al máximo posible.
- Grado promedio: promedio del número de conexiones por nodo.
- Coeficiente de agrupamiento promedio (*clustering*).
- Número de componentes conectadas.
- Tamaño del componente más grande (LCC, por sus siglas en inglés).

El camino promedio más corto no pudo calcularse por ser ambas redes desconectadas (múltiples componentes).

II-D. Análisis diferencial de aristas

Se calculó la matriz diferencial $\Delta = A_{\text{enfermo}} - A_{\text{sano}}$. Las aristas se clasificaron en tres categorías:

- Ganadas en la enfermedad: $\Delta = +1$.
- Perdidas en la enfermedad: $\Delta = -1$.
- Conservadas: presentes en ambas redes ($A_{\text{sano}} = 1$ y $A_{\text{enfermo}} = 1$).

Dado que las matrices son simétricas (grafo no dirigido), cada arista se contó una sola vez dividiendo la suma matricial entre dos. Adicionalmente, se calculó el cambio de grado por nodo, $\Delta k = k_{\text{enfermo}} - k_{\text{sano}}$, donde k_{enfermo} y k_{sano} representan

los grados de cada nodo en las dos condiciones, para identificar los nodos con mayor ganancia o pérdida de conectividad.

II-E. Pruebas estadísticas

Se compararon las distribuciones de grado de ambas redes mediante tres pruebas no paramétricas:

- Kolmogorov-Smirnov (KS): contrasta si ambas distribuciones de grado provienen de la misma distribución subyacente.
- Mann-Whitney U: prueba de suma de rangos para detectar diferencias en la ubicación de las distribuciones (hipótesis bilateral).
- Wilcoxon de rangos con signo: prueba pareada sobre el vector de diferencias de grado Δk, excluyendo nodos con $\Delta k = 0$. Evalúa si la mediana de Δk difiere de cero.

El nivel de significancia adoptado fue $\alpha = 0.05$. Para las pruebas no paramétricas se utilizó la biblioteca SciPy de Python [4].

II-F. Pruebas de permutación y modelo de configuración

Para evaluar si la diferencia observada en el grado promedio podía atribuirse al azar, se emplearon dos estrategias complementarias basadas en modelos nulos, ambas con 10,000 iteraciones.

En primer lugar, se aplicó una prueba de permutación clásica siguiendo el enfoque descrito en [5]: en cada iteración se combinaron los grados de ambas redes en un único conjunto, se mezclaron aleatoriamente, se dividieron en dos grupos del tamaño original y se calculó la diferencia de medias.

En segundo lugar, para controlar el efecto de la diferencia en el número de aristas entre redes, se construyó una distribución nula mediante el modelo de configuración: se generaron 10,000 pares de redes aleatorias preservando exactamente las secuencias de grado de cada condición, con las conexiones redistribuidas al azar. En ambos casos, la proporción de simulaciones en las que la estadística excedió el valor observado se tomó como p-valor empírico. El modelo de configuración se implementó con la biblioteca NetworkX [3].

II-G. Análisis funcional

Se incorporaron anotaciones funcionales de las rutas metabólicas a partir del archivo Pathways_Types_complete.txt. Se calculó el cambio de grado promedio por categoría ($\Delta\bar{k}$) como la media del vector Δk entre todos los nodos pertenecientes a cada categoría. Adicionalmente, se clasificaron las aristas ganadas, perdidas y conservadas según la categoría funcional de sus nodos extremo, contando cada nodo extremo por separado para capturar conexiones tanto intra- como inter-categoría.

III. Resultados

III-A. Resumen topológico comparativo

La Tabla I presenta las métricas topológicas globales de ambas redes. La red de individuos enfermos presentó sistemáticamente valores más altos en densidad, grado promedio y tamaño del componente más grande, con un número ligeramente menor de componentes conectadas.

Métrica	**Red Sana**	**Red Enferma**
Nodos	619	619
Aristas	876	1,215
Densidad	0.004580	0.006352
Grado promedio	2.8304	3.9257
Clustering promedio	0.303883	0.307501
Componentes	388	377
LCC (nodos)	51	66
Camino promedio	N/A (desconectada)	N/A (desconectada)

Cuadro I
RESUMEN DE MÉTRICAS TOPOLÓGICAS GLOBALES DE LAS REDES SANA Y ENFERMA. LCC: COMPONENTE MÁS GRANDE.

Categoría	**Número de aristas**
Ganadas en la enfermedad	609
Perdidas en la enfermedad	270
Conservadas	606

Cuadro II
CLASIFICACIÓN DIFERENCIAL DE ARISTAS ENTRE LA RED SANA Y LA RED ENFERMA.

III-B. Análisis diferencial de aristas

Al comparar ambas redes, se identificaron 609 aristas ganadas en el estado de enfermedad, 270 aristas perdidas y 606 aristas conservadas (Tabla II). Esto implica que aproximadamente el 50.1 % de las aristas de la red sana se mantienen en la red enferma, mientras que la red enferma incorpora casi el doble de aristas nuevas en relación con las que pierde.

III-C. Nodos con mayor cambio de conectividad

Los diez nodos con mayor ganancia de conectividad en el estado de enfermedad pasaron de un grado 0 (ausentes) en la red sana a un grado de 31 conexiones en la red enferma (Tabla III). Entre estos se encuentran `PWY-7277`, `PWY-7433`, `PWY-7112`, `PWY-7185`, `PWY-7426`, `PWY-7434`, `PWY-6564`, `PWY-6569`, `PWY-6861` y `PWY-6555`. Por el contrario, los nodos con mayor pérdida de conectividad perdieron entre 13 y 15 conexiones, entre los que destacan `TRIGLSYN-PWY`, `SPHINGOLIPID-SYN-PWY`, `LYSINE-AMINOAD-PWY`, `NADSYN-PWY` y `PWY-6981`.

III-D. Pruebas estadísticas sobre distribuciones de grado

Los resultados de las tres pruebas no paramétricas se presentan en la Tabla IV. Ninguna de las tres pruebas alcanzó significancia estadística al nivel $\alpha = 0.05$, lo que indica que las distribuciones de grado de ambas redes no difieren de forma detectablemente significativa con estas pruebas. Esta lectura es consistente con la Figura 1, donde los histogramas superpuestos y las ECDF comparativas muestran un traslape amplio entre ambas condiciones, a pesar de un desplazamiento moderado de la red enferma hacia grados más altos.

III-E. Pruebas de permutación y modelo de configuración

La prueba de permutación (10,000 iteraciones) mostró que la diferencia de grado promedio observada entre la red enferma y la sana ($\Delta\bar{k} = 1.0953$) es estadísticamente significativa ($p = 0.0067$). Este resultado contrasta con el de las pruebas no

Nodo (Ruta metabólica)	k sano	k enfermo	Δk
PWY-7277	0	31	+31
PWY-7433	0	31	+31
PWY-7112	0	31	+31
TRIGLSYN-PWY	15	0	-15
SPHINGOLIPID-SYN-PWY	15	0	-15
LYSINE-AMINOAD-PWY	15	0	-15
NADSYN-PWY	15	0	-15
PWY-6981	15	2	-13

Cuadro III
SELECCIÓN DE NODOS CON MAYOR CAMBIO DE CONECTIVIDAD (Δk). AZUL: MAYOR GANANCIA. ROJO: MAYOR PÉRDIDA.

Prueba	Estadístico	p-valor
Kolmogorov-Smirnov	0.053312	0.3428
Mann-Whitney U	187,119.50	0.4480
Wilcoxon de rangos con signo	10,484.00	0.2586

Cuadro IV
RESULTADOS DE LAS PRUEBAS ESTADÍSTICAS NO PARAMÉTRICAS. NINGÚN p-VALOR ES INFERIOR A $\alpha = 0.05$.

paramétricas clásicas y sugiere que, aunque la forma global de las distribuciones de grado es similar, la magnitud de la diferencia entre las medias es mayor de lo esperable por azar.

Para controlar el efecto de la diferencia en el número de aristas entre redes, se aplicó el modelo de configuración. La distribución nula resultante se centró en $\Delta\bar{k}_{\text{nulo}} = 0.944$, lo que refleja el efecto esperado del mayor número de aristas en la red enferma. El valor observado, $\Delta\bar{k} = 1.0953$, superó todas las simulaciones ($p < 0.0001$), lo que indica que la diferencia en la conectividad promedio no se explica únicamente por el incremento en el número de aristas, sino que refleja una reorganización estructural específica.

En conjunto, las Figuras 1, 2 y 3 articulan tres hallazgos complementarios. El alto traslape visual entre las distribuciones explica que las pruebas KS, Mann-Whitney y Wilcoxon no detecten diferencias significativas en la forma general de los grados. La distribución nula de la permutación se concentra alrededor de cero, mientras que la obtenida con el modelo de configuración se desplaza hacia valores positivos, acorde con el mayor número de aristas en la red enferma. Aun así, en ambos casos la diferencia observada se ubica en una región extrema, lo que respalda la significancia obtenida.

III-F. Análisis funcional del cambio de conectividad

Se mapearon las 619 rutas metabólicas a 12 categorías funcionales generales mediante las anotaciones de MetaCyc, de las cuales 616 contaban con categoría asignada. El análisis del cambio de grado promedio por categoría ($\Delta\bar{k}$) mostró que diez de las doce categorías presentaron una ganancia neta de conectividad en el estado de enfermedad (Figura 4). La categoría *Signaling and Regulation Metabolism* registró el mayor incremento promedio, aunque su alta variabilidad —asociada al reducido número de rutas que la integran ($n = 5$)— limita la solidez de este resultado. *Carbohydrate metabolism* presentó la segunda mayor ganancia con menor dispersión, lo que lo convierte en el resultado más robusto de esta categoría. En contraste, *Central metabolism and energy* fue la única categoría con pérdida neta de conectividad.

El análisis de aristas por categoría (Figura 5) mostró que *Carbohydrate metabolism* concentró el mayor número de aristas ganadas, con una proporción ganadas/perdidas marcadamente asimétrica. *Biosynthesis of Cofactors and Vitamins* destacó por presentar el mayor número de aristas conservadas, lo que sugiere que las rutas de esta categoría constituyen el núcleo estructuralmente estable de la red entre condiciones.

IV. DISCUSIÓN

Los resultados muestran que la red metabólica del estado de enfermedad es estructuralmente más densa y conectada que la del estado sano. El incremento en el número de aristas (de 876 a 1,215, un aumento del 38.7 %) y en el grado promedio (de 2.83 a 3.93) apunta a una mayor co-ocurrencia o activación funcional de rutas metabólicas en el microbioma de los individuos enfermos. El tamaño del componente más grande también creció (de 51 a 66 nodos), lo que indica una mayor interconexión entre módulos metabólicos.

El coeficiente de agrupamiento promedio es prácticamente idéntico en ambas redes (0.3039 vs. 0.3075), lo que sugiere que la estructura local de vecindad no cambia sustancialmente entre condiciones. La diferencia topológica reside principalmente en la escala global de conectividad, no en la cohesión local.

El análisis diferencial revela una asimetría notable: se ganan 609 aristas pero solo se pierden 270. Las rutas que pierden toda su conectividad en el estado enfermo, como TRIGLSYN-PWY, SPHINGOLIPID-SYN-PWY y NADSYN-PWY, son metabólicamente relevantes: involucran la síntesis de lípidos estructurales y cofactores esenciales [6], [7], cuya desaparición podría reflejar cambios en la composición microbiana o en la capacidad funcional del microbioma.

La discrepancia entre los resultados de las pruebas no paramétricas clásicas (no significativas) y los de las pruebas de permutación (significativas) merece atención. Las pruebas KS y Mann-Whitney evalúan la forma de las distribuciones y el orden de sus rangos, de modo que ambas pueden resultar similares en términos globales incluso cuando sus medias difieren. En cambio, tanto la prueba de permutación como el modelo de configuración se centran en la diferencia de medias y son más sensibles a desplazamientos sistemáticos

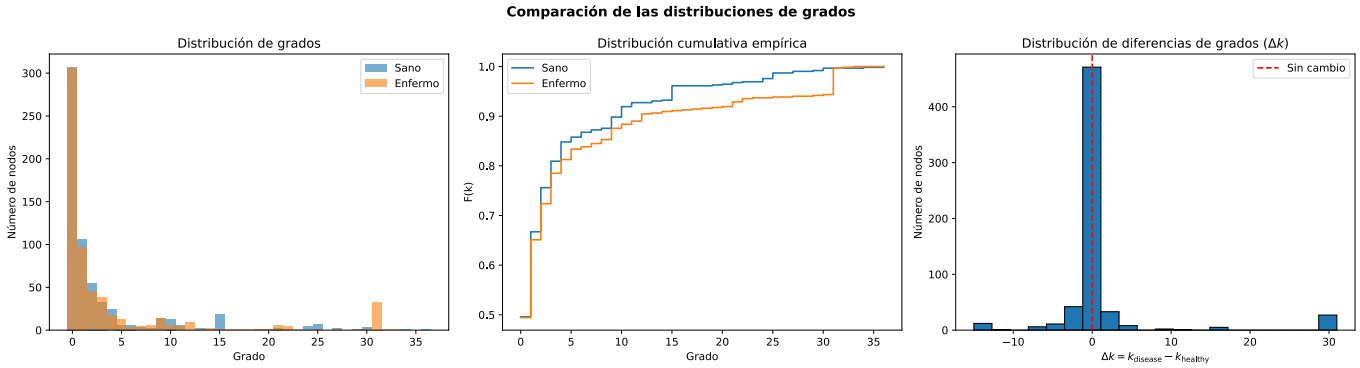

Figura 1. Comparación de las distribuciones de grado entre redes mediante histogramas superpuestos y ECDF comparativas, junto con la distribución de diferencias de grado (Δk) por nodo.

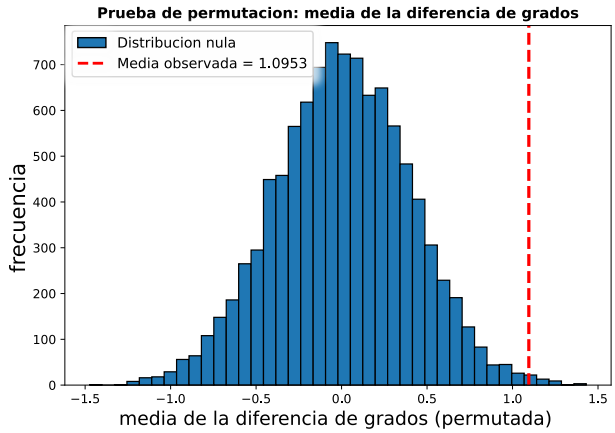

Figura 2. Distribución nula de la prueba de permutación para la diferencia de medias de los grados. La línea roja indica el valor observado.

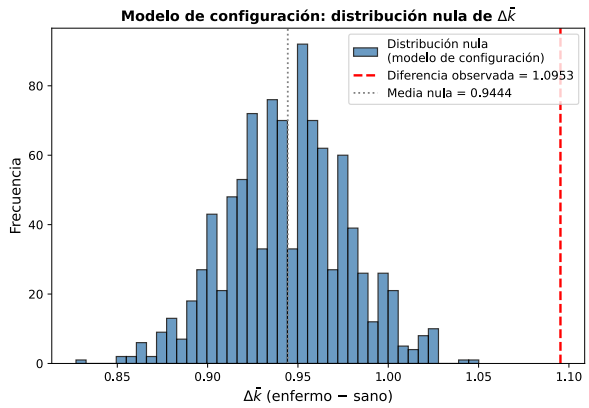

Figura 3. Distribución nula de $\Delta\bar{k}$ obtenida bajo el modelo de configuración, que preserva las secuencias de grado de ambas redes. La línea roja indica el valor observado; la línea punteada, la media de la distribución nula.

en la conectividad promedio. El hecho de que el resultado se mantenga significativo bajo el modelo de configuración, que ya incorpora el efecto del mayor número de aristas en la red enferma, refuerza la robustez del hallazgo.

El análisis funcional permite caracterizar con mayor resolución la reorganización topológica observada. La ganancia de conectividad no se distribuye de forma homogénea entre categorías: las rutas del metabolismo de carbohidratos concentran la mayoría de las aristas nuevas en la red enferma, mientras que las rutas del metabolismo central y energético son las únicas que presentan una pérdida neta de conectividad. Estos resultados son de naturaleza topológica y deben interpretarse como hipótesis estructurales que requieren validación experimental o integración con datos de abundancia relativa por individuo.

La principal limitación del análisis es que las matrices de adyacencia se tratan como datos estáticos binarios, sin considerar la abundancia relativa de las rutas ni la variabilidad entre individuos. Futuros análisis podrían incorporar pesos en las aristas y evaluar la significancia a nivel de nodo individual mediante corrección por comparaciones múltiples.

V. Conclusiones

- La red metabólica del estado de enfermedad es más densa y conectada que la del estado sano, con un incremento del 38.7 % en el número de aristas y un grado promedio 38.7 % mayor.
- El análisis diferencial indica que la transición al estado enfermo supone una ganancia neta de conectividad: 609 aristas nuevas frente a 270 pérdidas, además de 606 aristas conservadas.
- Rutas metabólicas de síntesis lipídica (TRIGLSYN-PWY, SPHINGOLIPID-SYN-PWY) y de biosíntesis de cofactores (NADSYN-PWY) pierden toda su conectividad en el estado de enfermedad, lo que podría tener relevancia biológica.
- La prueba de permutación ($p = 0.0067$) y el modelo de configuración ($p < 0.0001$) confirmaron que la diferencia observada en el grado promedio es estadísticamente significativa y no se explica únicamente por el mayor número de aristas en la red enferma, mientras que las pruebas no paramétricas distribucionales no detectaron diferencias significativas en la forma general de las distribuciones de grado.

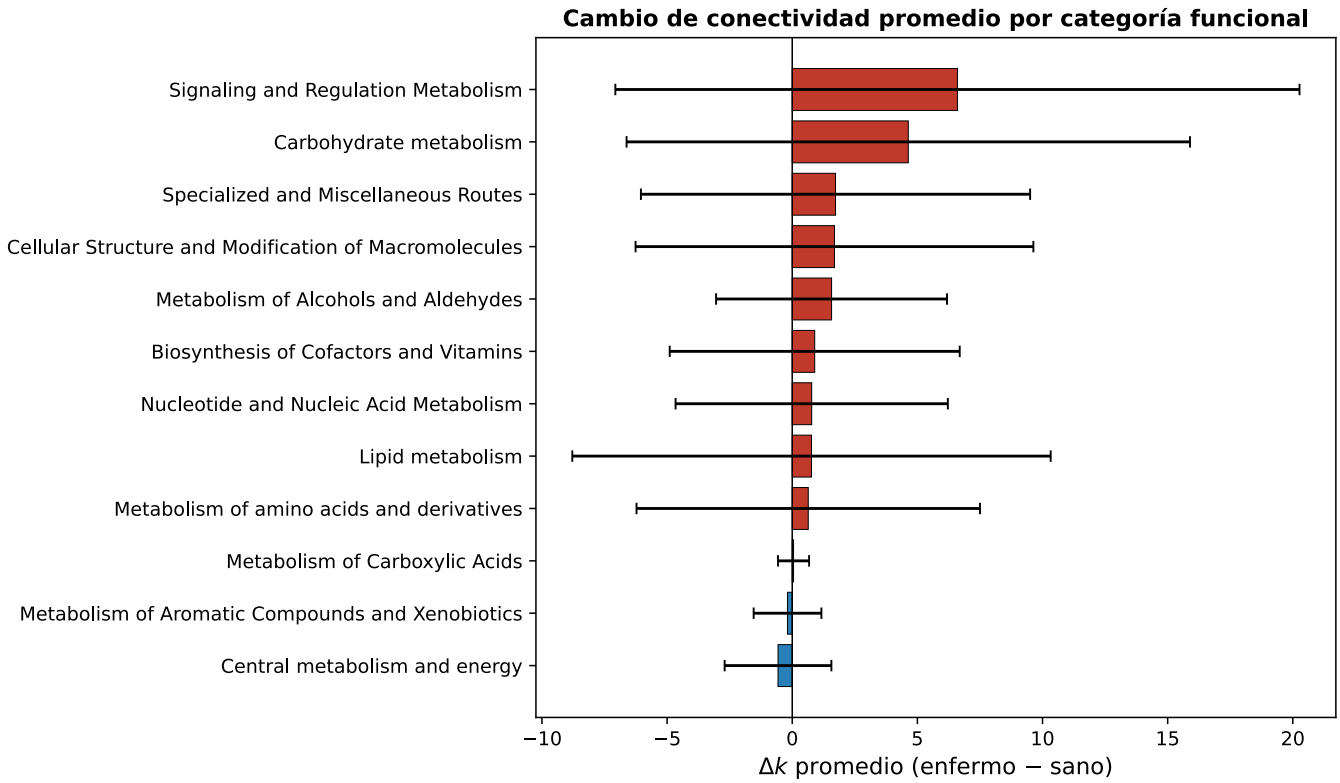

Figura 4. Cambio de grado promedio por categoría funcional ($\Delta\bar{k}$). Las barras rojas indican ganancia neta de conectividad en el estado de enfermedad; la barra azul, pérdida neta. Las líneas de error representan la desviación estándar.

- El análisis funcional mostró que la ganancia de conectividad se concentra en rutas de metabolismo de carbohidratos, y que el metabolismo central y energético es la única categoría con pérdida neta. Las rutas de biosíntesis de cofactores y vitaminas constituyen el núcleo estructuralmente más estable entre condiciones.
- El enfoque de redes metabólicas diferenciales constituye una herramienta útil para identificar cambios funcionales del microbioma asociados a estados de salud y enfermedad, y puede complementar los análisis taxonómicos y de expresión génica.

VI. Código

El análisis de la red fue realizado en un notebook de Jupyter. El código está disponible en el repositorio https://github.com/rubal501/redes-metagenomica.

VII. Declaración de uso de inteligencia generativa

En este proyecto se utilizó inteligencia generativa en dos etapas. En el notebook de análisis se utilizó Claude para agregar comentarios en Markdown y mejorar la presentación de las figuras, por ejemplo mediante la incorporación de ejes y etiquetas. Para el reporte se utilizó Prism de OpenAI para realizar correcciones de estilo sobre el borrador original, redactado en un archivo .docx, y para implementar al final un formato de LaTeX tipo IEEE.

Referencias

[1] E. Mathieu, V. Léjard, C. Ezzine, P. Govindin, A. Morat, M. Giat, N. Lapaque, J. Doré, and H. M. Blottière, "An insight into functional metagenomics: A high-throughput approach to decipher food–microbiota–host interactions in the human gut," *International Journal of Molecular Sciences*, vol. 24, no. 24, p. 17630, 2023.

[2] T. Ideker and N. J. Krogan, "Differential network biology," *Molecular Systems Biology*, vol. 8, p. 565, 2012, dOI: https://doi.org/10.1038/msb.2012.56.

[3] A. Hagberg, P. Swart, and D. S. Chult, "Exploring network structure, dynamics, and function using networkx," in *Proceedings of the 7th Python in Science Conference (SciPy 2008)*, 2008, pp. 11–16.

[4] P. Virtanen, R. Gommers, T. E. Oliphant *et al.*, "Scipy 1.0: Fundamental algorithms for scientific computing in python," *Nature Methods*, vol. 17, pp. 261–272, 2020, dOI: https://doi.org/10.1038/s41592-019-0686-2.

[5] V. C. Jardim, S. D. S. Santos, A. Fujita, and M. S. Buckeridge, "Bionetstat: a tool for biological networks differential analysis," *Frontiers in Genetics*, vol. 10, p. 594, 2019, dOI: https://doi.org/10.3389/fgene.2019.00594.

[6] A. Agrawal, H. Balcı, K. Hanspers, S. L. Coort, M. Martens, D. N. Slenter, F. Ehrhart, D. Digles, A. Waagmeester, I. Wassink *et al.*, "Wikipathways 2024: next generation pathway database," *Nucleic acids research*, vol. 52, no. D1, pp. D679–D689, 2024.

[7] P. D. Karp, R. Billington, R. Caspi, C. A. Fulcher, M. Latendresse, A. Kothari, I. M. Keseler, M. Krummenacker, P. E. Midford, Q. Ong *et al.*, "The biocyc collection of microbial genomes and metabolic pathways," *Briefings in bioinformatics*, vol. 20, no. 4, pp. 1085–1093, 2019.

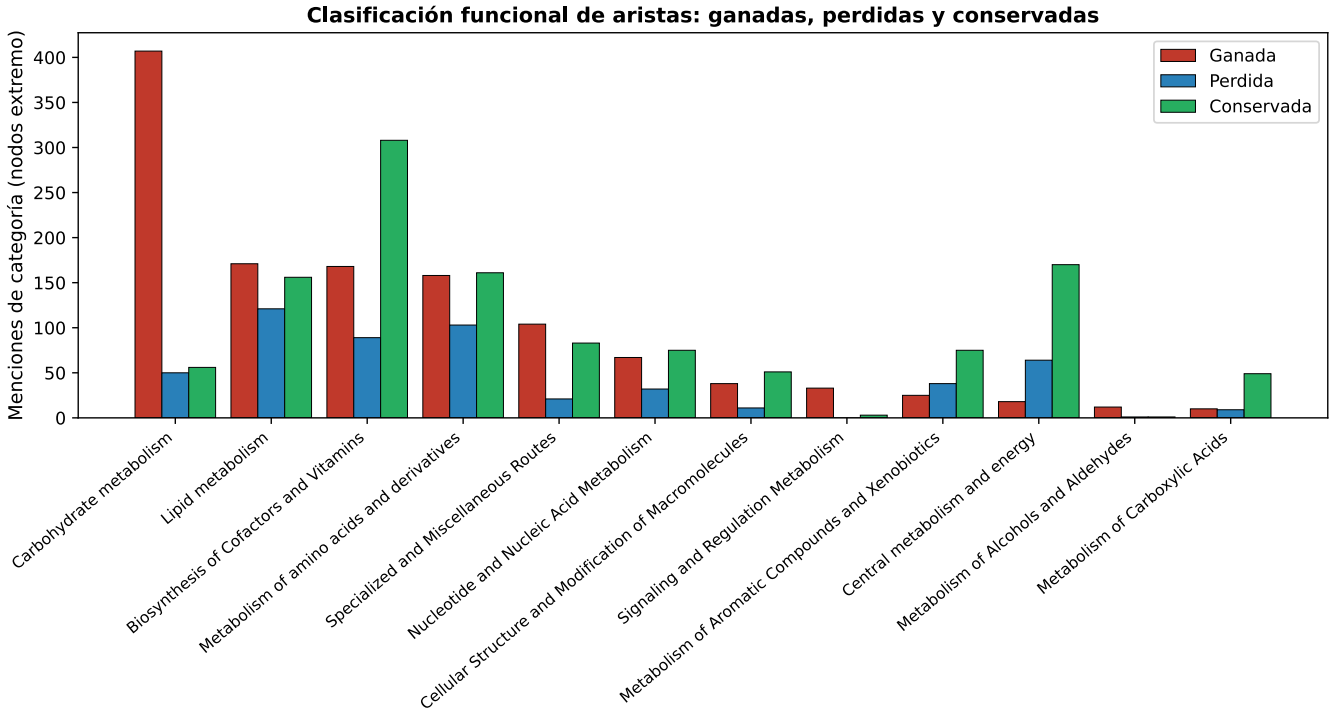

Figura 5. Clasificación funcional de aristas ganadas, perdidas y conservadas. Para cada arista se registra la categoría de cada nodo extremo; una arista puede involucrar nodos de dos categorías distintas. Se cuenta cada nodo extremo por separado (menciones de categoría por tipo de arista).